

Classificazione multimodale Sclerosi

Mariarosaria Rossi^a

^aUniversità degli studi di Salerno, Via Giovanni Paolo II, 132, Fisciano, 84084, SA, Italia

Abstract

La sclerosi multipla è una malattia neurodegenerativa caratterizzata dalla formazione di lesioni cerebrali rilevabili attraverso diverse modalità di risonanza magnetica. In questo lavoro proponiamo un approccio multimodale che combina immagini MRI e dati clinici per la segmentazione e la classificazione delle lesioni. Abbiamo utilizzato un dataset costituito da 60 pazienti, comprendente immagini Flair, T1 e T2, oltre a mappe di segmentazione delle lesioni, e informazioni cliniche associate. Dopo una fase di pre-processing e normalizzazione delle immagini, abbiamo implementato un modello di U-Net 2D per l'estrazione delle caratteristiche e la segmentazione delle lesioni. I risultati preliminari mostrano un miglioramento nella capacità del modello di individuare le aree lesionate, con valori del Dice coefficient fino a 0.45 nelle prime epoche, indicando la validità dell'approccio ma anche la necessità di ulteriori ottimizzazioni per superare i limiti dovuti allo sbilanciamento delle classi e alla dimensione del dataset.

Keywords: sclerosi multipla, classificazione multimodale, keyword 3, keyword 4

1. Introduzione

La sclerosi multipla (SM) rappresenta una delle principali patologie neurologiche croniche, caratterizzata dalla comparsa di lesioni demielinizzanti nel sistema nervoso centrale. La diagnosi e il monitoraggio della malattia si basano in gran parte sull'imaging cerebrale tramite risonanza magnetica (MRI), che consente di evidenziare le lesioni con modalità differenti (Flair, T1, T2). L'impiego di tecniche di deep learning, e in particolare delle reti convoluzionali (CNN) e delle architetture di tipo U-Net, ha mostrato un grande potenziale nella segmentazione automatica delle lesioni. Tuttavia, il problema rimane complesso a causa di fattori quali lo sbilanciamento tra tessuto sano e lesioni, la variabilità inter-paziente e la disponibilità limitata di dataset annotati. In questo lavoro proponiamo un approccio che integra le diverse modalità di risonanza e le informazioni cliniche dei pazienti, con l'obiettivo di sviluppare un sistema di classificazione multimodale capace di supportare la diagnosi e il monitoraggio della SM.

2. Dataset

Il dataset utilizzato è composto da 60 pazienti affetti da sclerosi multipla. Per ciascun paziente sono disponibili:

- Immagini MRI multimodali (Flair, T1, T2).
- Segmentazioni manuali delle lesioni (LesionSeg-Flair).
- Informazioni cliniche correlate (dati testuali e numerici).

Ogni volume MRI è stato acquisito in formato NIfTI (.nii). La presenza delle mappe di lesione consente l'addestramento supervisionato di modelli di segmentazione.

3. Data Pre-Processing

La fase di pre-processing ha riguardato sia i dati di imaging sia quelli clinici. Per quanto riguarda le immagini MRI, sono state effettuate le seguenti operazioni:

- Normalizzazione:** le intensità voxel sono state riportate nell'intervallo $[0,1]$ per ciascuna modalità. Così da ridurre la variabilità dovuta alle diverse scale di acquisizione e garantire che tutte le immagini contribuiscano in modo uniforme al processo di addestramento.
- Ridimensionamento dei volumi:** i dati originali presentavano dimensioni eterogenee a seconda del paziente e della modalità di acquisizione. Per uniformare l'input al modello, tutti i volumi sono stati riportati a una dimensione fissa di $128 \times 128 \times 64$, così da consentire un'elaborazione coerente e confrontabile.
- Estrazione delle slice:** i volumi tridimensionali sono stati convertiti in slice bidimensionali. Questa scelta ha permesso di aumentare la numerosità del dataset e di ridurre i requisiti computazionali, rendendo più gestibile l'addestramento della rete neurale convoluzionale.
- Filtraggio delle slice:** sono state considerate solo quelle contenenti lesioni, al fine di ridurre lo sbilanciamento classe lesione vs. background.
- Data Augmentation:** flip orizzontali/verticali e rotazioni, per aumentare la variabilità dei dati di addestramento.

Sul versante clinico, è stato effettuato il caricamento delle informazioni associate ai pazienti, con particolare attenzione all'Expanded Disability Status Scale (EDSS), indice di gravità della malattia. Sono state eseguite le seguenti operazioni:

- Pulizia dei dati clinici,** con eliminazione di eventuali inconsistenze o valori mancanti.

2. **One-hot encoding** delle variabili categoriche, così da poterle utilizzare nei modelli di apprendimento automatico.
3. **Analisi esplorativa dell'EDSS** tramite grafici descrittivi. La distribuzione dei punteggi (Figura 1) mostra una concentrazione di pazienti con valori bassi (0–2), indicativi di una disabilità lieve. Per scopi di classificazione binaria è stato inoltre definito un target basato su $EDSS < 4$ e $EDSS \geq 4$ (Figura 2), evidenziando uno sbilanciamento tra le due classi a favore della prima.




Figure 1: Distribuzione EDSS




Figure 2: Distribuzione target EDSS 4

4. Feature Extraction

Per l'estrazione delle feature è stata utilizzata una rete U-Net 2D.

- **Input:** slice multimodali (Flair, T1, T2).
- **Output:** maschera binaria della lesione.

- **Architettura:** encoder-decoder con 4 livelli, convoluzioni 3×3 , upsampling tramite transpose convolution e skip connections.
- **Loss function:** combinazione Binary Cross Entropy (BCE) + Dice Loss per mitigare lo sbilanciamento.
- **Ottimizzazione:** Adam optimizer ($lr=1e-3$) con scheduler adattivo.
- **Training:** 80 epoche con batch size variabile in funzione della capacità GPU.




Figure 3: Esempio di slice cerebrale del Paziente 4 (Z=40). Da sinistra a destra: Flair, segmentazioni delle lesioni, T1 e T2. Le diverse modalità mostrano il contrasto utile all'individuazione delle aree lesionate.

5. Model Description

Il modello utilizzato per la segmentazione delle lesioni è basato sull'architettura U-Net 2D, una rete convoluzionale ampiamente utilizzata in ambito medical imaging grazie alla sua capacità di combinare informazioni contestuali globali e dettagli locali.

La rete è strutturata secondo uno schema encoder-decoder simmetrico:

- **Encoder:** composto da quattro blocchi di convoluzione 3×3 con funzione di attivazione ReLU e batch normalization, seguiti da operazioni di max pooling 2×2 . Questa parte della rete ha il compito di estrarre feature gerarchiche riducendo progressivamente la dimensione spaziale delle immagini e aumentando la profondità dei canali.
- **Bottleneck:** collocato al centro della rete, cattura le rappresentazioni più astratte e di alto livello delle immagini, costituendo il ponte tra la fase di codifica e quella di decodifica.
- **Decoder:** include operazioni di upsampling realizzate tramite transpose convolutions, seguite da blocchi convoluzionali simili a quelli dell'encoder. In questa fase sono presenti le skip connections, che concatenano le feature dell'encoder con quelle corrispondenti del decoder, permettendo di recuperare dettagli spaziali persi durante il down-sampling.
- **Output layer:** un'operazione di convoluzione 1×1 riduce la profondità a un singolo canale, corrispondente alla mappa binaria delle lesioni, a cui viene applicata la funzione di attivazione sigmoid.

La scelta di utilizzare una U-Net 2D, piuttosto che una variante tridimensionale, è stata motivata da due fattori principali:

- (a) **Efficienza computazionale:** l'elaborazione 2D riduce notevolmente l'uso di memoria e i tempi di addestramento, risultando più adatta alle risorse disponibili.
- (b) **Disponibilità dei dati:** la conversione dei volumi 3D in slice bidimensionali ha consentito di aumentare la numerosità dei campioni, condizione particolarmente utile in presenza di un dataset relativamente ridotto.

Per affrontare lo sbilanciamento tra tessuto sano e lesioni, è stata impiegata una funzione di costo composta dalla combinazione di Binary Cross-Entropy (BCE) e Dice Loss, bilanciando così la penalizzazione degli errori pixel-wise con una misura globale di sovrapposizione.

6. Risultati e Discussioni

I risultati sperimentali indicano che il modello è effettivamente in grado di apprendere pattern utili per la segmentazione delle lesioni. In particolare, il valore della funzione di costo durante il training è sceso progressivamente da 0.60 fino a 0.18, mostrando una chiara tendenza alla convergenza. Parallelamente, il Dice coefficient calcolato sul set di validazione è passato da valori iniziali prossimi allo zero fino a raggiungere circa 0.45 nelle prime dodici epoche, stabilizzandosi successivamente in un intervallo compreso tra 0.38 e 0.43.

Questi risultati suggeriscono che il modello sia in grado di individuare le aree lesionate in maniera non casuale, sebbene la fase di plateau evidenzia i limiti intrinseci dell'architettura adottata. Tali limiti sono in parte attribuibili alla ridotta dimensione del dataset (60 pazienti) e allo squilibrio tra tessuto sano e lesioni, che rende complesso l'apprendimento di pattern più rari.

Per superare queste difficoltà e migliorare ulteriormente le performance, sarà necessario esplorare strategie complementari. Tra queste si annoverano l'adozione di funzioni di loss più sofisticate, come la Focal Loss o la Tversky Loss, l'impiego di architetture tridimensionali come la U-Net 3D, capaci di sfruttare appieno l'informazione volumetrica, e l'utilizzo di tecniche di data augmentation più avanzate per incrementare la variabilità del dataset e ridurre il rischio di overfitting.

7. Conclusioni

In questo lavoro abbiamo presentato un approccio multimodale per la segmentazione delle lesioni in pazienti con sclerosi multipla, combinando immagini MRI (Flair, T1, T2) e dati clinici come l'EDSS. Il modello basato su U-Net 2D ha dimostrato di essere in grado di apprendere pattern utili, con una riduzione del training loss da 0,60 a 0,18 e un Dice coefficient di validazione raggiunto fino a 0,45, stabilizzandosi successivamente intorno a 0,38–0,43. Questi risultati indicano che, pur in presenza di limitazioni dovute al numero di pazienti e allo sbilanciamento tra tessuto sano e lesioni, il metodo è promettente.

Il contributo principale del lavoro risiede nella dimostrazione del potenziale del framework multimodale in un contesto con dati limitati, e nell'identificazione delle criticità che ne ostacolano l'ottimizzazione. Tra i principali limiti emergono la natura 2D dell'approccio, che non sfrutta appieno la struttura volumetrica, e la scarsità di dati per regioni lesionate rare.

Come prospettive future, si suggerisce di estendere l'architettura a modelli 3D per cogliere meglio la continuità spaziale, esplorare funzioni di loss più sofisticate (Focal, Tversky) e adottare strategie di data augmentation e transfer learning per migliorare la generalizzazione.

Appendix A. Dettagli implementativi

Il modello è stato implementato in PyTorch 2.0 addestrato su GPU NVIDIA GeForce MX350 (2 GB VRAM). A causa delle limitazioni di memoria, è stato utilizzato un batch size variabile tra 1 e 4, con ottimizzatore Adam (learning rate iniziale 1×10^{-3}) e scheduler ReduceLROnPlateau.

L'intero processo di addestramento è stato strutturato in due fasi:

- (a) Preprocessing e feature extraction, con normalizzazione delle immagini MRI nell'intervallo $[0, 1]$, ridimensionamento dei volumi a $128 \times 128 \times 64$, conversione in slice 2D e data augmentation tramite rotazioni e flip.
- (b) Model training e evaluation, basato su una U-Net 2D con quattro livelli di convoluzione 3×3 , batch normalization e attivazione ReLU, addestrata con loss function combinata Binary Cross-Entropy + Dice Loss.

L'addestramento è durato 80 epoche, con un tempo medio di circa 3–4 minuti per epoca (5 ore complessive).

References

- [1] O. Ronneberger, P. Fischer, and T. Brox, "U-Net: Convolutional Networks for Biomedical Image Segmentation," *Medical Image Computing and Computer-Assisted Intervention (MICCAI)*, pp. 234–241, 2015.
- [2] F. Milletari, N. Navab, and S.-A. Ahmadi, "V-Net: Fully Convolutional Neural Networks for Volumetric Medical Image Segmentation," *International Conference on 3D Vision (3DV)*, pp. 565–571, 2016.
- [3] K. Kamnitsas, C. Ledig, V.F.J. Newcombe, J.P. Simpson, A.D. Kane, D.K. Menon, D. Rueckert, and B. Glocker, "Efficient Multi-Scale 3D CNN with Fully Connected CRF for Accurate Brain Lesion Segmentation," *Medical Image Analysis*, vol. 36, pp. 61–78, 2017.
- [4] S. Valverde, A. Oliver, and X. Lladó, "Improving automated multiple sclerosis lesion segmentation with a cascaded 3D convolutional neural network," *NeuroImage*, vol. 155, pp. 159–168, 2017.
- [5] F. Isensee, P. Kickingereder, W. Wick, M. Bendszus, and K.H. Maier-Hein, "No New-Net," *International MICCAI Brainlesion Workshop*, pp. 234–244, 2019.
- [6] Y. Zhang, M. Brady, and S. Smith, "Multiple Sclerosis Lesion Segmentation with CNNs and Transfer Learning," *NeuroImage: Clinical*, vol. 21, pp. 101–113, 2019.
- [7] X. Lladó, A. Garcia-Diaz, S. Oliver, and S. Valverde, "Segmentation of multiple sclerosis lesions: a review of automated approaches," *NeuroImage: Clinical*, vol. 17, pp. 104–115, 2019.

- [8] S. Wang, Q. Chen, and Z. Yang, “Deep learning in multiple sclerosis lesion segmentation: A survey,” *Frontiers in Neuroscience*, vol. 16, 2022.